

Praktikum 2: Laporan Praktikum Mandiri 2 Machine Learning

Maryam Hasnaa' Syamila - 0110222067

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: hasyamil4@gmail.com

Link Notebook Colab: [Tugas2.ipynb](#)

Link GitHub:

<https://github.com/maryamhasnaasyamila/machine-learning/tree/tugas/praktikum/praktikum01>

1. Sinkronisasi Drive, Import Library, Load Data, Inspeksi Awal

```
# Hubungkan Google Colab ke Google Drive
from google.colab import drive
drive.mount('/content/gdrive')

# Import pandas
import pandas as pd

# Baca file CSV dari drive
df = pd.read_csv('/content/gdrive/MyDrive/SEMESTER 7/Machine Learning/praktikum02/datasets/day.csv')

# Tampilkan jumlah baris dan kolom
print("Jumlah data (rows, cols):", df.shape)

# Tampilkan 5 baris pertama
df.head()
```

Mounted at /content/gdrive

Jumlah data (rows, cols): (731, 16)

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01	1	0	1	0	6	0	2	0.344167	0.363625	0.805833	0.160446	331	654	985
1	2	2011-01-02	1	0	1	0	0	0	2	0.363478	0.353739	0.696087	0.248539	131	670	801
2	3	2011-01-03	1	0	1	0	1	1	1	0.196364	0.189405	0.437273	0.248309	120	1229	1349
3	4	2011-01-04	1	0	1	0	2	1	1	0.200000	0.212122	0.590435	0.160296	108	1454	1562
4	5	2011-01-05	1	0	1	0	3	1	1	0.226957	0.229270	0.436957	0.186900	82	1518	1600

- **Sinkronisasi Drive:** Perintah `drive.mount()` digunakan untuk menghubungkan Google Colab dengan Google Drive. Ini adalah tahap penting agar *notebook* dapat mengakses dan membaca file dataset `day.csv` yang tersimpan di dalam Drive.
- **Import Library:** *Library* Pandas diimpor dengan alias `pd`. Pandas adalah alat utama dalam analisis data di Python yang digunakan untuk memanipulasi data dalam format tabel (DataFrame).
- **Pemuatan Data:** Data dari file `day.csv` dibaca dan dimuat ke dalam sebuah DataFrame bernama `df` menggunakan fungsi `pd.read_csv()`.
- **Inspeksi Awal:**
 - Untuk mengetahui ukuran dataset, perintah `df.shape` dijalankan. Hasilnya menunjukkan bahwa dataset ini terdiri dari 731 baris (data) dan 15 kolom (fitur).
 - Fungsi `df.head()` digunakan untuk menampilkan lima baris pertama dari data. Ini berguna untuk mendapatkan gambaran awal mengenai isi dan struktur kolom-kolom yang ada, seperti `dteday`, `season`, `temp`, dan `cnt` (jumlah total sewa).

2. Membagi Data untuk Train 80% dari Total Dataset

```
# Split awal: ambil Train = 80% dan sisakan Test = 20%
from sklearn.model_selection import train_test_split

RANDOM_STATE = 42

# Train
train_df, test_df = train_test_split(df, test_size=0.2, random_state=RANDOM_STATE, shuffle=True)

print("Step 1: Buat Train (80%) selesai.")
print("Jumlah total data:", len(df))
print("Jumlah data Train (80%):", len(train_df))

# Tampilkan 5 baris teratas dari Train
display(train_df.head())
```

Step 1: Buat Train (80%) selesai.
Jumlah total data: 731
Jumlah data Train (80%): 584

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
682	683	2012-11-13	4	1	11	0	2	1	2	0.343333	0.323225	0.662917	0.342046	327	3767	4094
250	251	2011-09-08	3	0	9	0	4	1	3	0.633913	0.555361	0.939565	0.192748	153	1689	1842
336	337	2011-12-03	4	0	12	0	6	0	1	0.299167	0.310604	0.612917	0.095783	706	2908	3614
260	261	2011-09-18	3	0	9	0	0	0	1	0.507500	0.490537	0.695000	0.178483	1353	2921	4274
543	544	2012-06-27	3	1	6	0	3	1	1	0.697500	0.640792	0.360000	0.271775	1077	6258	7335

- Fungsi `train_test_split`: Fungsi ini berasal dari *library* Scikit-learn (`sklearn`) dan digunakan untuk membagi dataset secara acak. Proporsi Pembagian: Dataset dibagi dengan proporsi 80% untuk data latih dan 20% untuk data uji. Ini diatur melalui parameter `test_size=0.2`.
- Parameter Penting:
 - `shuffle=True`: Memastikan data diacak sebelum dibagi untuk menghindari bias jika data terurut berdasarkan pola tertentu.
 - `random_state=42`: Berfungsi sebagai "kunci" untuk pengacakan. Dengan menetapkan nilai ini, hasil pembagian data akan selalu sama setiap kali kode dijalankan, sehingga eksperimen menjadi reproduibel (dapat diulang dengan hasil yang sama).
- Hasil: Dari total 731 data, sebanyak 584 data dialokasikan sebagai `train_df` (data latih). Sisa 147 data akan menjadi `test_df` (data uji).

3. Menampilkan Data Valid dari 10% Data Train

```
# Ambil 10% dari train_df sebagai validation
# (train_df di-reassign menjadi train tanpa bagian validation)
train_df, val_df = train_test_split(train_df, test_size=0.1, random_state=RANDOM_STATE, shuffle=True)

print("Step 2: Buat Validation (10% dari Train) selesai.")
print("Jumlah data Train (setelah diambil validation):", len(train_df))
print("Jumlah data Validation (10% dari Train awal):", len(val_df))

# Tampilkan 5 baris teratas dari Validation
display(val_df.head())
```

Step 2: Buat Validation (10% dari Train) selesai.
Jumlah data Train (setelah diambil validation): 525
Jumlah data Validation (10% dari Train awal): 59

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
325	326	2011-11-22	4	0	11	0	2	1	3	0.416667	0.421696	0.962500	0.118792	69	1538	1607
410	411	2012-02-15	1	1	2	0	3	1	1	0.348333	0.351629	0.531250	0.181600	141	4028	4169
92	93	2011-04-03	2	0	4	0	0	0	1	0.378333	0.378767	0.480000	0.182213	1651	1598	3249
47	48	2011-02-17	1	0	2	0	4	1	1	0.435833	0.428658	0.505000	0.230104	259	2216	2475
508	509	2012-05-23	2	1	5	0	3	1	2	0.621667	0.584612	0.774583	0.102000	766	4494	5260

- **Sumber Data:** Data validasi diambil dari `train_df` (data latih awal yang berjumlah 584). Proporsi: Sebanyak 10% dari `train_df` diambil untuk menjadi `val_df` (data

validasi). Ini diatur dengan

`test_size=0.1`.

- **Hasil:**

- Data validasi (`val_df`) kini berjumlah 59 data.
- Data latih (`train_df`) yang tersisa (setelah diambil untuk validasi) menjadi 525 data.

4. Menampilkan Data Train (20% dari Total Data)

```
# Tampilkan Test yang sudah disisihkan di Step 1
print("Step 3: Testing set (20% dari total)")
print("Jumlah data Testing:", len(test_df))
display(test_df.head())

# Final sanity check: jumlah seluruh subset harus sama dengan total dataset
total = len(train_df) + len(val_df) + len(test_df)
print("\nTotal (train + val + test) =", total)
print("Total dataset asli      =", len(df))
assert total == len(df), "ERROR: Jumlah train+val+test tidak sama dengan total dataset!"
print("✅ Pembagian berhasil dan jumlahnya cocok dengan total dataset.")
```

Step 3: Testing set (20% dari total)
Jumlah data Testing: 147

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
703	704	2012-12-04	4	1	12	0	2	1	1	0.475833	0.469054	0.733750	0.174129	551	6055	6606
33	34	2011-02-03	1	0	2	0	4	1	1	0.186957	0.177878	0.437826	0.277752	61	1489	1550
300	301	2011-10-28	4	0	10	0	5	1	2	0.330833	0.318812	0.585833	0.229479	456	3291	3747
456	457	2012-04-01	2	1	4	0	0	0	2	0.425833	0.417287	0.676250	0.172267	2347	3694	6041
633	634	2012-09-25	4	1	9	0	2	1	1	0.550000	0.544179	0.570000	0.236321	845	6693	7538

Total (train + val + test) = 731
Total dataset asli = 731
✅ Pembagian berhasil dan jumlahnya cocok dengan total dataset.

- **Inspeksi Data Uji:** Data uji (`test_df`) yang merupakan 20% dari total dataset ditampilkan. Jumlah datanya adalah 147. Data ini akan digunakan hanya pada tahap evaluasi final model.
- **Sanity Check:** Dilakukan verifikasi dengan menjumlahkan semua subset data (`train_df`, `val_df`, dan `test_df`). Totalnya harus sama dengan jumlah data pada dataset asli.
- **Hasil Pengecekan:** Total data dari gabungan ketiga subset adalah 731, yang cocok dengan jumlah data asli. Perintah `assert` memastikan bahwa jika jumlahnya tidak cocok, program akan berhenti dan menampilkan error. Dalam kasus ini, proses pembagian dinyatakan berhasil.

5. Membuat rangkuman pembagian dataset

Tahap ini memberikan gambaran yang jelas mengenai hasil akhir dari seluruh proses pemisahan data

```
print("📊 Ringkasan Pembagian Dataset:")
print("Training set   :", len(train_df))
print("Validation set  :", len(val_df))
print("Testing set     :", len(test_df))
print("Total           :", len(train_df) + len(val_df) + len(test_df))
```

📊 Ringkasan Pembagian Dataset:
Training set : 525
Validation set : 59
Testing set : 147
Total : 731