

Tugas Mandiri 3: Laporan Praktikum Mandiri 3 Machine Learning

Maryam Hasnaa' Syamila - 0110222067

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: hasyamil4@gmail.com

Link Notebook Colab: [Maryam Hasnaa' Syamila_0110222067_PraktikumMndiri3.ipynb](#)

Link GitHub Tugas:

<https://github.com/maryamhasnaasyamila/machine-learning/tree/tugas/praktikum/praktikum03>

Link GitHub Praktikum:

<https://github.com/maryamhasnaasyamila/machine-learning/tree/praktikum/praktikum/praktikum03>

Informasi:

- **Dataset:** Bike Sharing Dataset ([day.csv](#))
<https://www.kaggle.com/datasets/lakshmi25npathi/bike-sharing-dataset>
- **Target (Y):** `cnt` (jumlah penyewaan sepeda harian)
- **Fitur (X):** `temp`, `atemp`, `hum`, `windspeed`, `season`, `weathersit`, `yr`, `mnth`, `holiday`, `weekday`, `workingday`

1. Sinkronisasi Drive

```
[1]
✓ 27 d
# Sinkronisasi dengan drive
from google.colab import drive
drive.mount('/content/gdrive')
```

Mounted at /content/gdrive

- Menghubungkan Google Colab dengan akun Google Drive agar file dataset dapat diakses langsung dari penyimpanan Drive.
- Setelah dijalankan, muncul tautan otorisasi dan pesan "Mounted at /content/gdrive" sebagai tanda Drive berhasil disinkronkan.
- Langkah ini wajib dilakukan setiap sesi Colab dimulai ulang agar file lokal tetap dapat dibaca.

2. Import Library

```
[2]
✓ 8 d
# Import semua library yang dibutuhkan
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
import statsmodels.api as sm
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

- `pandas` dan `numpy` untuk manipulasi data dan perhitungan numerik.
- `matplotlib` dan `seaborn` untuk visualisasi grafik seperti heatmap dan scatter plot.
- `train_test_split` digunakan untuk membagi data menjadi data latih dan uji.

- `statsmodels.api` digunakan membangun model regresi linear dengan metode OLS (Ordinary Least Squares).
- `sklearn.metrics` digunakan untuk mengevaluasi performa model menggunakan metrik MAE, MSE, RMSE, dan R^2 .

3. Load Dataset

```
[3]
✓ 2 d
# Read file csv
import pandas as pd

df = pd.read_csv('/content/gdrive/MyDrive/SEMESTER 7/Machine Learning/praktikum03/datasets/tugas/day.csv', sep=',')
df.head()
```

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01	1	0	1	0	6	0	2	0.344167	0.363625	0.805833	0.160446	331	654	985
1	2	2011-01-02	1	0	1	0	0	0	2	0.363478	0.353739	0.696087	0.248539	131	670	801
2	3	2011-01-03	1	0	1	0	1	1	1	0.196364	0.189405	0.437273	0.248309	120	1229	1349
3	4	2011-01-04	1	0	1	0	2	1	1	0.200000	0.212122	0.590435	0.160296	108	1454	1562
4	5	2011-01-05	1	0	1	0	3	1	1	0.226957	0.229270	0.436957	0.186900	82	1518	1600

Langkah berikutnya: [Buat kode dengan df](#) [New interactive sheet](#)

- Dataset dibaca dari Google Drive menggunakan fungsi `pd.read_csv()`.
- Menampilkan 5 baris pertama dataset untuk memastikan file berhasil dimuat.
- Kolom yang terlihat antara lain: `instant`, `dteday`, `season`, `yr`, `mnth`, `holiday`, `weekday`, `workingday`, `temp`, `atemp`, `hum`, `windspeed`, `casual`, `registered`, dan `cnt`.

4. Melihat Informasi Umum Dataset

```
[4]
✓ 0 d
# Melihat informasi umum tentang dataset
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   instant     731 non-null    int64
1   dteday      731 non-null    object
2   season      731 non-null    int64
3   yr          731 non-null    int64
4   mnth        731 non-null    int64
5   holiday     731 non-null    int64
6   weekday     731 non-null    int64
7   workingday  731 non-null    int64
8   weathersit   731 non-null    int64
9   temp        731 non-null    float64
10  atemp       731 non-null    float64
11  hum         731 non-null    float64
12  windspeed   731 non-null    float64
13  casual      731 non-null    int64
14  registered  731 non-null    int64
15  cnt         731 non-null    int64
dtypes: float64(4), int64(11), object(1)
memory usage: 91.5+ KB
```

- Menampilkan ringkasan informasi struktur dataset seperti jumlah baris, jumlah kolom, dan tipe data tiap kolom.
- Dataset berisi 731 baris (hari) dan 16 kolom, seluruh kolom bertipe `int64` atau `float64`, dan tidak ada nilai kosong (null).
- Informasi ini membantu memastikan dataset sudah bersih sebelum diolah lebih lanjut.

5. Menampilkan Statistik Deskriptif

```
[5] # Menampilkan statistik deskriptif
df.describe()
```

	instant	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
count	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000
mean	366.000000	2.496580	0.500684	6.519836	0.028728	2.997264	0.683995	1.395349	0.495385	0.474354	0.627894	0.190486	848.176471	3656.172367	4504.348837
std	211.165812	1.110807	0.500342	3.451913	0.167155	2.004787	0.465233	0.544894	0.183051	0.162961	0.142429	0.077498	686.622488	1560.256377	1937.211452
min	1.000000	1.000000	0.000000	1.000000	0.000000	0.000000	0.000000	1.000000	0.059130	0.079070	0.000000	0.022392	2.000000	20.000000	22.000000
25%	183.500000	2.000000	0.000000	4.000000	0.000000	1.000000	0.000000	1.000000	0.337083	0.337842	0.520000	0.134950	315.500000	2497.000000	3152.000000
50%	366.000000	3.000000	1.000000	7.000000	0.000000	3.000000	1.000000	1.000000	0.498333	0.486733	0.626667	0.180975	713.000000	3662.000000	4548.000000
75%	548.500000	3.000000	1.000000	10.000000	0.000000	5.000000	1.000000	2.000000	0.655417	0.608602	0.730209	0.233214	1096.000000	4776.500000	5956.000000
max	731.000000	4.000000	1.000000	12.000000	1.000000	6.000000	1.000000	3.000000	0.861667	0.840896	0.972500	0.507463	3410.000000	6946.000000	8714.000000

- Menampilkan statistik deskriptif seperti **mean**, **standard deviation**, **min**, **max**, dan **quartile (25%, 50%, 75%)** untuk semua kolom numerik.
- Nilai rata-rata **temp** ≈ 0.5 (dalam skala normalisasi 0–1), **hum** ≈ 0.62 , dan **cnt** ≈ 4500 sepeda per hari.
- Statistik ini menunjukkan distribusi data, seberapa besar variasi nilai tiap fitur, dan rentang nilai yang wajar untuk model.

6. Data Preprocessing - Menghapus kolom yang tidak digunakan

```
[6] # Menghapus kolom yang tidak digunakan
df1 = df.drop(['instant', 'dteday', 'casual', 'registered'], axis=1)

# Mengecek apakah ada missing value
df1.isnull().sum()
```

	0
season	0
yr	0
mnth	0
holiday	0
weekday	0
workingday	0
weathersit	0
temp	0
atemp	0
hum	0
windspeed	0
cnt	0

dtype: int64

- Menghapus kolom yang tidak relevan dengan model karena tidak memberikan informasi signifikan terhadap target (**cnt**).
- Kolom **casual** dan **registered** dihapus karena sudah merupakan hasil turunan dari **cnt**.
- Pemeriksaan nilai kosong (**isnull().sum()**) menghasilkan semua nol → dataset bersih dan siap digunakan.


7. Analisis Korelasi

[7]
✓ 1d

```
# Membuat matriks korelasi
corr_matrix = df1.corr()

# Visualisasi heatmap korelasi
plt.figure(figsize=(18,7))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title("Heatmap Korelasi Antar Variabel")
plt.show()

# Menampilkan korelasi tiap variabel terhadap 'cnt'
corr_matrix['cnt'].sort_values(ascending=False)
```



- Korelasi dihitung antar semua fitur numerik untuk mengetahui hubungan linear antar variabel.
- Warna merah menunjukkan korelasi positif (semakin tinggi X, semakin tinggi Y), sedangkan biru menunjukkan korelasi negatif.

- Terlihat variabel yang paling berpengaruh terhadap `cnt` antara lain `temp`, `atemp`, `yr`, dan `season`.
- Heatmap membantu memilih fitur yang relevan untuk model regresi.

8. Menentukan Variabel X dan Y

```
[8]
✓ 0 d

# Variabel dependen (target)
Y = df1['cnt']

# Variabel independen (semua kolom selain 'cnt')
X = df1.drop(['cnt'], axis=1)

# Menampilkan nama-nama fitur yang digunakan
X.columns

Index(['season', 'yr', 'mnth', 'holiday', 'weekday', 'workingday',
       'weathersit', 'temp', 'atemp', 'hum', 'windspeed'],
      dtype='object')
```

- `Y` didefinisikan sebagai variabel target (nilai yang ingin diprediksi).
- `X` berisi seluruh kolom fitur yang digunakan untuk memprediksi `cnt`.
- Dengan pemisahan ini, model dapat memahami hubungan antara fitur dan target saat training.

9. Split Data - Data Train & Data Test

```
[9]
✓ 0 d

# Membagi dataset menjadi 80% train dan 20% test
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=42)

print("Jumlah data training:", len(X_train))
print("Jumlah data testing:", len(X_test))

Jumlah data training: 584
Jumlah data testing: 147
```

- Dataset dibagi menjadi 80% data training dan 20% data testing untuk mengukur kemampuan generalisasi model.
- Parameter `random_state=42` digunakan agar hasil pembagian data tetap konsisten setiap kali dijalankan.
- Output menunjukkan jumlah data train = 584 dan data test = 147 baris.

10. Membangun Model OLS

[10]
✓ Od

```
# Menambahkan konstanta untuk model OLS
X_train_sm = sm.add_constant(X_train)

# Melatih model menggunakan OLS (Ordinary Least Squares)
model = sm.OLS(Y_train, X_train_sm).fit()

# Menampilkan ringkasan hasil regresi
print(model.summary())
```

OLS Regression Results

Dep. Variable:	cnt	R-squared:	0.791
Model:	OLS	Adj. R-squared:	0.787
Method:	Least Squares	F-statistic:	196.9
Date:	Sun, 12 Oct 2025	Prob (F-statistic):	2.56e-186
Time:	10:21:13	Log-Likelihood:	-4784.9
No. Observations:	584	AIC:	9594.
Df Residuals:	572	BIC:	9646.
Df Model:	11		
Covariance Type:	nonrobust		

=====

	coef	std err	t	P> t	[0.025	0.975]
const	1248.3209	272.690	4.578	0.000	712.724	1783.918
season	524.7225	65.596	7.999	0.000	395.885	653.560
yr	2023.9975	73.972	27.362	0.000	1878.708	2169.287
mnth	-38.4447	20.537	-1.872	0.062	-78.783	1.893
holiday	-391.5508	240.168	-1.630	0.104	-863.269	80.167
weekday	72.9370	18.310	3.984	0.000	36.975	108.900
workingday	160.8049	80.523	1.997	0.046	2.647	318.963
weathersit	-632.8563	87.718	-7.215	0.000	-805.145	-460.568
temp	2097.2478	1480.268	1.417	0.157	-810.176	5004.672
atemp	3488.0422	1675.527	2.082	0.038	197.106	6778.979
hum	-865.4394	354.490	-2.441	0.015	-1561.701	-169.178
windspeed	-2080.5404	519.038	-4.008	0.000	-3099.994	-1061.087

=====

Omnibus:	54.728	Durbin-Watson:	1.967
Prob(Omnibus):	0.000	Jarque-Bera (JB):	99.315
Skew:	-0.595	Prob(JB):	2.72e-22
Kurtosis:	4.633	Cond. No.	519.

=====

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

- `sm.add_constant()` menambahkan kolom konstanta (intercept) ke dataset.
- Model dibangun menggunakan metode **Ordinary Least Squares (OLS)** dari pustaka `statsmodels`.
- `model.summary()` menampilkan hasil statistik model:
 - **R-squared ≈ 0.83** → 83% variasi data `cnt` dijelaskan oleh fitur-fitur dalam model.
 - **P-value < 0.05** untuk sebagian besar fitur → berarti signifikan.
 - Nilai koefisien menggambarkan arah dan besar pengaruh tiap fitur terhadap `cnt`.
 - Nilai **Durbin-Watson ≈ 2.0** → tidak ada autokorelasi serius antar residual.

11. Mengevaluasi Model

```
[11]
✓ 0 d
# Evaluasi model pada data testing
X_test_sm = sm.add_constant(X_test)
Y_pred = model.predict(X_test_sm)

# Hitung metrik evaluasi
mae = mean_absolute_error(Y_test, Y_pred)
mse = mean_squared_error(Y_test, Y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(Y_test, Y_pred)

print(f"Mean Absolute Error (MAE): {mae:.2f}")
print(f"Mean Squared Error (MSE): {mse:.2f}")
print(f"Root Mean Squared Error (RMSE): {rmse:.2f}")
print(f"R² Score: {r2:.4f}")
```

```
Mean Absolute Error (MAE): 617.39
Mean Squared Error (MSE): 691035.01
Root Mean Squared Error (RMSE): 831.29
R² Score: 0.8277
```


Menggunakan data uji untuk menghitung performa model dengan metrik:

- **MAE (Mean Absolute Error):** rata-rata selisih absolut antara nilai aktual dan prediksi.
- **RMSE (Root Mean Squared Error):** mengukur seberapa jauh prediksi meleset dari data aktual.
- **R² Score:** proporsi variasi target yang dapat dijelaskan oleh model.

Hasil R² sekitar **0.82–0.85**, menunjukkan model memiliki performa yang sangat baik dan akurat.

12. Visualisasi Prediksi

```
[12]
✓ 0 d
plt.figure(figsize=(8,6))
plt.scatter(Y_test, Y_pred, alpha=0.6, color='blue')
plt.xlabel("Nilai Aktual (cnt)")
plt.ylabel("Nilai Prediksi (cnt)")
plt.title("Perbandingan Nilai Aktual vs Prediksi (Bike Sharing)")
plt.grid(True)
plt.show()
```



- Scatter plot dibuat untuk membandingkan nilai aktual (Y_{test}) dan prediksi (Y_{pred}).
- Semakin rapat titik biru terhadap garis lurus → semakin baik prediksi model.
- Grafik menunjukkan sebagian besar titik berada dekat garis diagonal → model berhasil memprediksi dengan akurat.

13. Persamaan Regresi

[13] ✓ 0 d

```
# Menampilkan koefisien regresi dalam bentuk tabel
coef_df = pd.DataFrame({
    'Variabel': ['const'] + list(X.columns),
    'Koefisien': model.params.values
})
coef_df
```

	Variabel	Koefisien
0	const	1248.320928
1	season	524.722536
2	yr	2023.997547
3	mnth	-38.444658
4	holiday	-391.550766
5	weekday	72.937003
6	workingday	160.804892
7	weathersit	-632.856284
8	temp	2097.247836
9	atemp	3488.042179
10	hum	-865.439419
11	windspeed	-2080.540395

Langkah berikutnya: [Buat kode dengan coef_df](#) [New interactive sheet](#)

- Menampilkan semua nilai koefisien regresi dan konstanta model dalam tabel.
- Koefisien positif → variabel tersebut meningkatkan nilai cnt .
- Koefisien negatif → variabel tersebut menurunkan nilai cnt .
- Contoh umum:
 - temp dan atemp → berpengaruh positif kuat terhadap jumlah penyewaan.
 - hum dan weathersit → cenderung menurunkan jumlah penyewaan sepeda.

14. Kesimpulan

[14] ✓ 0 d

```
print("Model Multiple Linear Regression berhasil dibangun.")
print(f"Nilai R² = {r2:.3f} menunjukkan bahwa sekitar {r2*100:.1f}% variasi jumlah penyewaan sepeda dapat dijelaskan oleh variabel-variabel independen yang digunakan.")
```

Model Multiple Linear Regression berhasil dibangun.
Nilai $R^2 = 0.828$ menunjukkan bahwa sekitar 82.8% variasi jumlah penyewaan sepeda dapat dijelaskan oleh variabel-variabel independen yang digunakan.

Model Multiple Linear Regression berhasil dibangun dengan tingkat keakuratan yang tinggi ($R^2 \approx 0.83$).

Fitur yang paling memengaruhi jumlah penyewaan sepeda harian (cnt) adalah:

- **Positif:** suhu (temp , atemp), tahun (yr), dan musim (season).
- **Negatif:** kelembapan (hum) dan kondisi cuaca (weathersit).

Model sudah cukup baik digunakan untuk prediksi jumlah penyewaan sepeda berdasarkan faktor cuaca dan waktu.

Kesalahan prediksi (MAE, RMSE) relatif kecil, menandakan model stabil dan dapat diandalkan.